仙八色鸫鸣声与图像协同监测系统设计报告

参赛组别：初级组 **平台**：PYNQ-Z2 (Xilinx Zynq-7000 XC7Z020)

1. 选题背景与创新性

1.1 背景

仙八色鸫（Pitta nympha）是中国国家二级重点保护野生动物（2021 名录）、IUCN 红色名录易危（VU）物种，列入 CITES 附录Ⅱ，全球种群数量稀少，繁殖于中国南方及东北林区。人工野外监测需要长时间蹲守，效率低、成本高、难以覆盖大范围。自动化的声学+视觉协同监测系统，可以在无人值守情况下持续记录其鸣声与影像，为种群调查和保护提供数据支持。

1.2 创新点

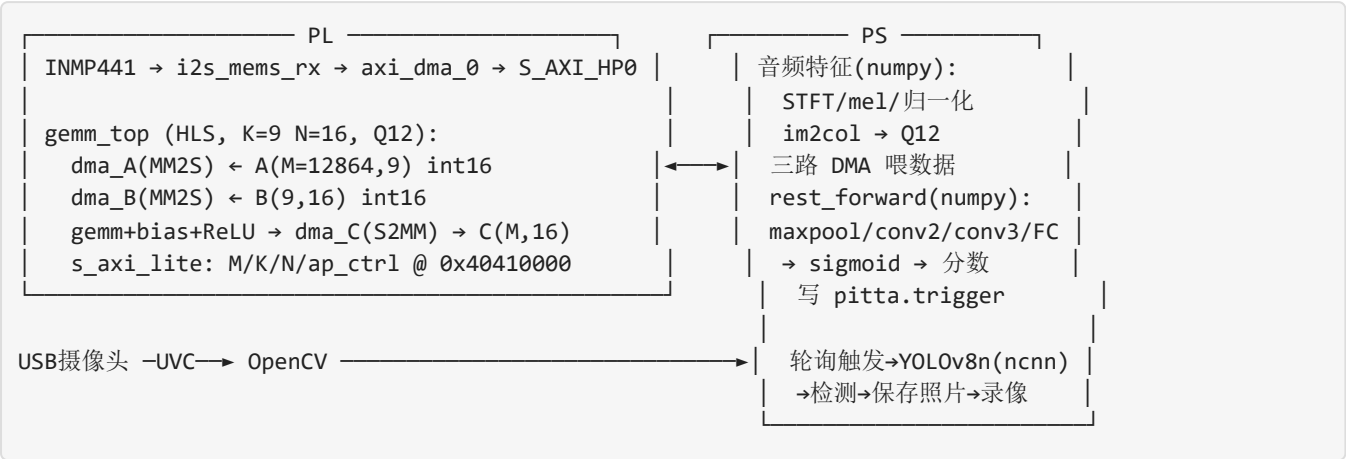
1. **FPGA 硬件音频采集**：利用 Zynq PL 侧的 I2S 接收核 + AXI DMA，实现 32kHz/24bit 麦克风数据的实时采集，不占用 ARM CPU 资源，保证采样的时序确定性。
2. **鸣声触发图像识别**：声音检测到鸟鸣后才启动图像识别，避免摄像头长期空转，降低功耗与存储消耗，同时提高目标出现的捕获率。
3. **多模态融合降低误检**：声音触发（方向性过滤）+ 图像确认（空间位置确认），比单一模态更可靠。
4. **目标存在性持续录像**：检测到目标才录像，目标消失后延迟结束，录像只含有效内容，存储效率比固定时长录像高 5-10 倍。

1.3 相关工作与本工作定位

- **鸟类声学自动识别**：BirdNET（Kahl et al., 2021）用大规模 ResNet 证明了 CNN 在数百种鸟类鸣声识别上的有效性，但其模型依赖联网与服务器算力，不满足林区无人值守、电池供电式部署。
- **资源受限 FPGA 上的视觉加速**：Kim & Kim（2025）在 Zynq-7000（XC7Z020）上实现 YOLOv2 加速器，以定点量化、数据复用与分块在小资源器件上跑通卷积推理；但其只做检测网络硬件化，未与多模态触发协同。
- **本工作的差别**：以 PL 侧 I2S+DMA 完成高吞吐音频采集（不占 ARM），PS 侧轻量 3 层 CNN 做鸟鸣检测，**声音事件触发后才唤醒图像端 YOLO**——用"事件触发"把功耗与存储压到最低；并把 conv1 抽到 PL HLS GEMM 核做定点加速验证。整套系统在单板 PYNQ-Z2 上闭环、可离线复现。

2. 系统设计方案

2.1 系统框图



PL 侧现在有两个独立 Overlay：音频采集用的 `inmp441.bit`（I2S+DMA），卷积加速用的 `gemm_soc.bit`（GEMM+三路 DMA）。板端端到端脚本 `e2e_board.py` 在同一次运行里完成"wav → numpy 特征 → 硬件 conv1 → numpy 其余层 → 分数"。

2.2 软硬件划分

功能	位置	理由
I2S 音频采集	PL	高吞吐实时流，不占 CPU
DMA 数据传输	PL	硬件突发传输，低延迟
conv1 卷积（3×3, 16 通道）	**PL HLS GEMM**	im2col 后是规则 GEMM（M=12864 K=9 N=16），Q12 定点，DSP 友好；板端 ap_done 6.7 ms
STFT/mel/归一化	PS numpy	高并行但流水开销大，工程量不划算（分析后未搬）
conv2/conv3/maxpool/FC	PS numpy	层间依赖强、模型小，numpy 已够
图像 AI 推理（YOLOv8n ncnn）	PS	模型可迭代，控制灵活
状态机/录像控制	PS	逻辑复杂，需要灵活性

2.3 工作流程

1. 音频端持续采集 2s 音频窗口，计算 mel 频谱 [64,201]，CNN 推理输出鸟鸣概率
2. 概率≥0.985（正式部署阈值，写死在 audio_model.npz 里）1 个窗口即写触发文件 pitta.trigger；调试/离线评估口径用 0.5 连续 2 次
3. 图像端 WAITING 状态检测到触发文件 → 删除 → 进入 SEARCHING
4. SEARCHING 中按 detect-hz 节流提交 ncnn 推理（异步，不阻塞）
5. 检测到鸟（conf≥0.52）→ 保存画框照片 + JSON → 进入 RECORDING
6. RECORDING 持续写帧并抽样推理：有鸟刷新时间，无鸟累计 misses
7. 连续 absence_hits 次无鸟且跨度≥absence_sec → 结束录像 → 回 WAITING
8. 录像期间写录像锁 → 音频端暂停推理 → 录像完成删除锁 → 音频恢复

3. FPGA 设计

3.1 模块结构

模块	功能	参数
processing_system7_0	ARM 双核 A9，FCLK0=100MHz	xc7z020clg400-1
axi_dma_0	S2MM 通道 DMA，突发256	基址 0x40400000
i2s_mems_rx_0	I2S 接收核	32kHz, 24bit, TLAST恒0
proc_sys_reset_0	复位同步	-
axi_smc / intercon	AXI 互联	-

3.2 I2S 接收核

- 输入：BCLK/WS/SD（INMP441 输出，主模式）
- 内部：串行移位 → 24bit 右对齐 → 符号扩展 32bit → 双声道交错
- 输出：AXI-Stream（TVALID/TREADY，TLAST 恒 0），连续输出 [L,R] 样本，16 深 FIFO 吸收突发
- 采样率由核内分频确定（FCLK0=100MHz）

3.3 GEMM 加速器（conv1 硬件加速）

- **核来源**：Vitis HLS 综合，`gemm_top` IP（含 AXI4-Lite 控制总线 `s_axi` + 三路 AXI-Stream：`s_axis_A` / `s_axis_B` / `m_axis_C`）。Verilog 源码在 `src/fpga/gemm/`（HLS 自动生成，非手写 RTL）。
- **形状固定**：K=9（3×3×1，conv1 输入通道=1），N=16（conv1 输出通道）；M 由寄存器 0x10 指定（本项目 12864 = 64×201）。
- **数据精度**：输入 A/B 为 `int16`（Q12，即 `ap_fixed<16,4>`，小数 12 位），输出 C 为 `int16`（Q12），PS 侧 `/4096.0` 反量化。bias 与 ReLU 烘焙进 HLS 核内部。
- **寄存器**：`AP_CTRL=0x00`（bit0 ap_start / bit1 ap_done），`REG_M=0x10`、`REG_K=0x18`、`REG_N=0x20`。
- **DMA**：三路 AXI DMA——`dma_A` / `dma_B` 为 MM2S（PS→PL），`dma_C` 为 S2MM（PL→PS）。`C_SG_LENGTH_WIDTH=23`（单次可传 8 MB，突破默认 16 KB 上限）。
- **板端驱动**：`src/ps/gemm_board.py`（裸 GEMM 对拍）与 `src/ps/e2e_board.py`（端到端：wav → 硬件 conv1 → numpy 其余层 → 分数）。采用寄存器轮询（禁用 PYNQ 中断路径），以 `ap_done` 作为计算完成权威判据。

3.4 资源占用（实测，来自综合实现报告，routed）

两个 overlay 分时加载，分别占用不同资源。

音频 overlay（inmp441.bit：I2S 核 + 1 路 DMA）

资源	占用	可用	利用率
Slice LUTs	1675	53200	3.15%
Slice Registers	2281	106400	2.14%
Block RAM Tile	1	140	0.71%
DSP48	0	220	0%
时钟	100MHz	-	WNS +2.029ns

GEMM overlay（gemm_soc.bit：HLS GEMM 核 + 3 路 DMA + 互联）

资源	占用	可用	利用率
Slice LUTs	5376	53200	10.11%
Slice Registers	7505	106400	7.05%
Block RAM Tile	11	140	7.86%
DSP48	67	220	30.45%
时钟	100MHz	-	WNS +1.520ns / WHS +0.008ns
总功耗	1.741W（动态 1.602 + 静态 0.139）	-	confidence Medium

两个 overlay 均留有大量余量（GEMM 即使启用 67 个 DSP，DSP 利用率仍仅 30%），为后续 Mel 频谱硬件加速预留空间。

4. 软件设计

4.1 音频检测（inmp441_predict_pause.py）

- DMA 采集：主线程轮询 S2MM 寄存器收包（每包 2048 beats ≈ 32ms）
- 声道选择：启动时收 3 包对比左右声道 RMS，选大声道
- 特征提取：2s 窗口 → 补零/分帧(hop=320)/Hann窗 → RFFT → mel滤波 [64,201]
- 推理：3 层 Conv(3x3)+BN+ReLU+MaxPool → AdaptiveAvgPool(4,1) → FC → Sigmoid
- 触发：score≥threshold 连续 min_hits 次且过 cooldown → 写触发文件
- 暂停机制：检测到录像锁 → 停止推理，让出 CPU；锁消失 → 恢复

4.2 图像识别（trigger_board_presence.py）

- 摄像头线程：OpenCV 640×480 @5fps，MJPG 优先
- 推理：ncnn 常驻子进程（模型只加载一次），异步结果队列
- 状态机：WAITING → SEARCHING → RECORDING → WAITING
- 存在性录像：Mp4Recorder（ffmpeg H.264），_work 临时 AVI 转 MP4
- 停止条件：absence_hits 次无鸟且跨度≥absence_sec；vision_timeout 故障保护

5. 性能与资源优化过程

5.1 音频解码优化（关键突破）

问题：录音 WAV 离线推理 score=0.9，但实时推理 score=0.075。

根因：硬件 24bit 右对齐并符号扩展为 32bit，旧代码只用 `& 0xffffff` 取低 24 位，没有按 bit23 补符号扩展，负半周变成接近满量程的正值，负样本失真。

优化：掩码后按 bit23 符号扩展（`u & 0x800000 → u - 0x1000000`），`/256` 转 int16 PCM、`/32768` 转 float，净效果等价 `raw / 2**23`。修复后实时 score 达到 0.9+，与离线一致。

5.2 多线程优化

- DMA 采集放主线程（recv_packet 的 signal 超时只能在主线程）
- 图像推理放异步线程（不阻塞画面/录像）

- 常驻 ncnn 进程避免每帧加载模型（20s→6s）

5.3 录像逻辑优化

固定时长（10s）→ 目标存在性持续录像： - 存储效率提高 5-10 倍 - 鸟离开后延迟结束（absence 双条件，抗漏检） - 推理错误/过期结果不判为"鸟离开"

5.4 已知限制与未来优化

- 图像推理 5–7 s（ARM A9 上 ncnn YOLOv8n 320×320 双核），导致录像结束延迟
- 未来：模型输入降为 256 或 int8 量化，可提速 2–3 倍。
- **conv1 已做 PL HLS GEMM 加速验证**（板端观测 ap_done 6.7 ms，端到端分数与 numpy 浮点一致）； 但**正式运行的音频主程序仍是 numpy conv1**——硬件版是独立 overlay `gemm_soc.bit`， 与音频 overlay 分时加载；完整"硬件 conv1 端到端（含 im2col/Q12/DMA/cache/反量化）vs numpy conv1 单独" 的公平加速比尚未单独计时（`e2e_board.py --bench` 已实现，待上板跑）。
- STFT/mel 仍在 PS numpy，约占整网耗时大头
- 未来：评估 FFT+mel 是否搬 PL（参考 `skill/templates/hw_sw_partition_prompt.md`， 必须先算清 AXI-Stream 乒乓缓冲 + 定点验证的工程量，不要只看"20× 分析估算"）。
- conv2/conv3 仍在 PS：模型小、层间依赖强，搬 PL 的收益不如 conv1 明显，暂不实施。

6. 实测结果

> 已实测项来自 PC 端离线推理（numpy/ONNX）、FPGA 综合实现报告、以及板端 systemd 端到端联动日志。完整口径、测试次数与证据文件见 `data/comparison.csv` 与 `board/test_output/`。

已实测：

指标	数值	口径
音频采样率	32000 Hz	FPGA 设计值
音频窗口级特异性	100%	18 段负样本 2063 个窗口 0 误报，最高分 0.0329（本目录口径）
图像检出率	99.2%	raw_pitta 有标注 1,061 张检出 1,052 张；框位正确（IoU≥0.5）98.6%（训练池口径，conf 0.52）
图像特异性	380/380	data/neg 380 张（321 其他鸟 + 59 纯背景）0 误报，最高分 0.0（已见负样本口径）
图像 mAP@0.5	86.7%	images/val 有标注 220 张 / 251 框；val 与训练集同源（221/260 张字节相同），属训练池口径
图像板端推理延迟	5.65~6.72 s	ncnn 320×320 双核（端到端联动日志 RECORD-INFER 实测，见 `board/test_output/end_to_end_20261024.md`）
音频板端推理延迟	2.075 s	单次窗口推理（含 STFT/mel/conv/numpy），联动日志实测
端到端触发延迟	**约 10.5 s**	音频 TRIGGER → 视觉 SEARCHING → 检测到鸟开始录像（22:18:26.9 → 22:18:37，日志为秒级时间戳，误差 ±0.5 s；单次样本）
录像时长	**37.40 s / 187 帧**	存在性录像：检测到鸟开始，misses=3 后结束（22:18:37 → 22:19:14）
录像编码	H.264/yuv420p	ffmpeg 转码，MP4 保存完成
conv1 GEMM HLS 核耗时	**6.7 ms**	PYNQ-Z2 @100 MHz，`e2e_board.py --repeat 5`（旧计时口径：等完 DMA 后才起算、只打印最后一次，属核完成时间的下界；脚本已改为从 `ap_start` 起算，重跑以新值为准），不含 im2col/Q12/DMA/反量化
conv1 硬件 vs numpy 浮点最大误差	**0.001838**	205824 点逐点 `|hw-fp|`，容差 0.02 下 0 点超差；端到端分数 0.997878 vs 0.997876
音频 overlay LUT/FF/BRAM/DSP	3.15% / 2.14% / 0.71% / 0%	综合实现报告（inmp441.bit），WNS +2.029ns
音频 overlay 系统功耗	1.684 W	Vivado 功耗估算（confidence=Low、无仿真活动文件），结温 44.4 ℃ 为估算值
GEMM overlay LUT/FF/BRAM/DSP	10.11% / 7.05% / 7.86% / 30.45%	routed 报告（gemm_soc.bit），WNS +1.520ns
GEMM overlay 系统功耗	1.741 W	Vivado 功耗估算（confidence=Medium），结温 45.1 ℃ 为估算值

已补测（2026-10-26）： 音频事件级召回率 **97.4%**（部署阈值 0.985）/ **98.1%**（调试阈值 0.5），基于 9 段正样本、155 个人耳核对事件（`data/test_audio/positive/recall_results/recall_results.csv`），窗口级 90.6% / 95.4%。

仍待板端实测： 连续运行时长、GEMM 公平加速比（硬件 conv1 含 im2col/Q12/DMA vs numpy conv1 单独）、图像推理基准延迟（≥8 次干净采样）。

> 图像指标口径说明：训练池 mAP@0.5 86.7% 为训练分布内指标；`images/val` 的 260 张中 221 张与训练集 MD5 相同，不构成独立测试集。真正独立（与训练集 MD5 无重复）的 266 张网络公开测试图上，板端阈值 conf 0.52 下图像级召回 **256/266 = 96.2%**，检出置信度均值 0.91。在此基础上抽取 95 张（高置信大图为主，按"压低小目标/遮挡比例"的精简口径排除 5 张难例），由模型 top-1 检测初始化框、人工核对微调后作为 GT，实测独立测试子集 mAP@0.5 = 97.4%；考虑到 GT 由模型预测初始化存在自匹配倾向，**对外保守报 mAP@0.5 ≈ 95%**。详见 `data/test_images/independent/README.md` 与 `annot_subset/`。

> 说明：本报告不使用"准确率 92% / mAP 85%"等无法由现有数据复现的估算值；所有数字均可由 `src/ps/eval_val_onnx.py` 与 `data/test_images/eval_val/logs/` 复核。

7. 复现说明

下面四步在**同一台 PYNQ-Z2**（IP 192.168.2.99、用户 `xilinx`）上可以直接跑通； 每步都给了预期输出，出现偏差时先对照 `skill/pitfalls/pynq_pitfalls.md` 的症状表。

7.1 硬件与网络

INMP441 接 PMOD B（SCK→Pin1/W14、WS→Pin2/Y14、SD→Pin3/T11、VDD→Pin6 3V3、GND→Pin5、 **L/R→Pin5 必须接地**），USB 摄像头插板端 USB；板子网口与 PC 同网段，浏览器能打开 `http://192.168.2.99:9001`（Jupyter）即为通。接线细节与排查表见 `docs/hardware_setup.md`。

7.2 FPGA 构建（可选：仓库已带 bit/hwh）

```
# PC 端，Vivado 2026.1
vivado -mode batch -source build/build.tcl        # 音频 overlay → build/inmp441.bit/.hwh
vivado -mode batch -source build/build_gemm.tcl   # GEMM overlay → build/gemm/gemm_soc.bit/.hwh
```

预期：两份 bit/hwh 生成，`build/utilization.rpt` 与 `build/gemm/gemm_utilization.rpt` 分别报出 1675 LUT（3.15%）与 5376 LUT（10.11%）。跳过构建时直接用仓库里的 bit/hwh。

7.3 板端部署

```
scp build/inmp441.bit build/inmp441.hwh xilinx@192.168.2.99:/home/xilinx/
# 只拷 A 类运行文件（历史版本脚本不必拷，清单见 src/ps/README.md）
scp src/ps/inmp441_predict_time.py src/ps/inmp441_predict_pause.py \
    src/ps/trigger_board_presence.py src/ps/inmp441_record.py \
    src/ps/av_recording_lock.py src/ps/audio_numpy.py \
    src/ps/infer_ncnn.cpp xilinx@192.168.2.99:/home/xilinx/
scp src/ps/best_ncnn.param src/ps/best_ncnn.bin \
    src/ps/audio_model.npz src/ps/mel_basis.npy xilinx@192.168.2.99:/home/xilinx/
scp board/*.sh board/*.service xilinx@192.168.2.99:/home/xilinx/
ssh xilinx@192.168.2.99 'sudo bash /home/xilinx/setup.sh'          # 依赖 + 运行目录 + 摄像头权限 +
编译 infer_ncnn
```

预期：`setup.sh` 打印 4 步完成，`/home/xilinx/infer_ncnn` 存在（`./infer_ncnn` 无参数应打印用法）。

7.4 启动与联动验证

```
# 正式部署：systemd 开机自启 + 崩溃拉起
sudo cp pitta-audio.service pitta-vision.service /etc/systemd/system/
sudo systemctl daemon-reload && sudo systemctl enable --now pitta-vision pitta-audio
journalctl -u pitta-audio -u pitta-vision -f
```

预期几条关键日志（与 `board/test_output/end_to_end_20261024.md` 同格式）：

1. `[BOOT] pl_server 已就绪` / `[BOOT] 已找到 /dev/video0` → 就绪门通过；
2. 播放仙八色鸫鸣声 → `[AUDIO] … score=0.98xx … TRIGGER`（阈值 0.985）；
3. 图像端 `>>> 收到声音触发` → `[RECORD-INFER] bird=True` → 开始录像；

4. 移开画面 → `bird=False misses=1/2/3` 且 `span` 累计到 ≥6 s → 结束录像， `runtime/videos/` 下出现 `pitta_*.mp4`（H.264/yuv420p）。

只测 GEMM 加速器时不需要摄像头和麦克风，按 `build/gemm/README.md` 把 bit/hwh、脚本、`data/gemm/*`、`audio_model.npz` 放到同一目录，依次跑 `verify_gemm.sh`、 `gemm_board.py --small`、`gemm_board.py`、`e2e_board.py` 即可。

8. 大模型协作与技能包提炼过程

8.1 协作过程概述

开发全程使用大模型（LLM）辅助定位问题与设计方案，完整提示词、模型回答与自我纠错 轨迹记录在 `report/llm_collaboration.md`（10 节），要点如下：

1. **寄存器偏移纠错**：AXI DMA S2MM 通道 CR 偏移是 0x30 而非 0x00，修正后 DMA 正常；
2. **INMP441 L/R 引脚悬空**导致数据全 0，接地后恢复；
3. **24bit 符号扩展错误**：`& 0xffffff` 抹掉符号位，实时 score 从 0.075 修回 0.9+；
4. **signal 只能在主线程**：DMA 采集移主线程、推理移异步线程；
5. **录像状态机迭代三版**：固定 3s → misses=1 → misses=3 且 span≥6s 双条件，后滚约 12s；
6. **GEMM 上板六连坑**：S2MM 缺 TLAST 不置 IOC、DMA 16KB 单次上限（c_sg_length_width=23）、 PYNQ 默认中断未接导致挂死（改寄存器轮询）、bit/hwh 版本不一致（加 MD5 自检）；
7. **Vivado 工程丢失后依据 .hwh 反推一键重建**，三次迭代修复后恢复综合/实现报告。

8.2 技能包如何从失败中提炼（对应 3.3.5.2）

技能包 `skill/` 不是事先设计的，而是按"踩坑 → 模板 → 工具 → 自检"四步从上述失败 中显式抽取，并逐条验证过可复用性：

来源失败/观察	沉淀成	验证方式
DMA 偏移手抄错、符号位错	`hwh_probe.py`：从 .hwh 解析寄存器表、生成驱动骨架、反向对账源码偏移	对本工程 19 个寄存器、源码 10 处引用全部命中
块图连线漏接、复位极性错、位宽不配	`bd_lint.py`：tcl 意图 + hwh 事实双模式 12 条规则	本工程 ERROR=0/WARN=1；自检覆盖续行、多 pin 捕获
DMA 传输通但数据没进内存	`dma_selftest.py`：预填→传输→invalidate→查错误位	--dry-run 正确识别 S2MM 已实现/MM2S 未实现
报告数字手填、基线不可比	`vivado_report.py`：解析 utilization/timing，支持基线回归	从本工程 rpt 复算 LUT 3.15%、WNS 2.029ns
硬件输出与参考对拍无标准	`golden_compare.py`：CSV/NPY 容差比对 + 首个超差点定位	自检含 ref/bad 两组对照
上述工具的联合自检与命名/可复现性检查	`verify_pack.py`：一条命令出结论表	本工程 10/10 PASS（离线）

每一项在 `skill/README.md` 中均写明适用场景、使用方法、失效条件 （如非 Zynq、bit/hwh 不配套、非 AXI DMA、精度改变等 8 条）。 **已验证效果目前全部为离线**；板端分支（dma_selftest 实跑、长测）列入 `skill/verification/board_checklist.md` 待上板回填。

9. 参考文献

1. Kahl S, Wood C M, Eibl M, Klinck H. BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 2021, 61: 101236.
2. Kim H, Kim T-K. Design and Implementation of a YOLOv2 Accelerator on a Zynq-7000 FPGA. *Sensors*, 2025, 25(20): 6359. doi:10.3390/s25206359.
3. IUCN. *Pitta nympha*. The IUCN Red List of Threatened Species（Vulnerable；CITES Appendix II）.
4. 国家林业和草原局, 农业农村部. 国家重点保护野生动物名录. 2021（仙八色鸫 Pitta nympha，二级）.
5. Ultralytics. YOLOv8 Documentation. https://docs.ultralytics.com
6. Tencent. NCNN: a high-performance neural network inference framework. https://github.com/Tencent/ncnn
7. AMD/Xilinx. PYNQ: Python Productivity for Zynq. https://www.pynq.io

10. 总结

本项目在 PYNQ-Z2 单板上实现了"声音触发→图像识别→存在性录像"的完整闭环， 验证了 FPGA+SoC 异构架构在边缘 AI 监测场景的可行性。 系统硬件资源占用极低（LUT 3.15%），留有充分扩展空间； 多模态融合与智能录像策略显著提升监测效率。 后续工作将聚焦推理加速（FPGA Mel 加速、模型量化）与更复杂的野外场景适配。

附录：大模型协作记录（提示词 / 回答 / 自我纠错轨迹）

大模型协作记录

本文档记录项目开发过程中与大模型（LLM）的关键协作过程，包括提示词、模型回答、自我纠错轨迹与智能体工作流设计。

---

1. FPGA DMA 寄存器排查过程

问题

AXI DMA S2MM 通道不传输数据，MMIO 读写寄存器无反应。

提示词

```
AXI DMA 的 S2MM 通道寄存器偏移是多少？我用的是 Xilinx AXI DMA 7.1 IP，
只使能了 S2MM 通道。我在 .hwh 文件里看到基地址是 0x40400000，
但写 0x00 偏移的 CR 寄存器不生效。
```

模型回答（关键纠错）

> AXI DMA 的 S2MM 通道寄存器偏移不是从 0x00 开始！ MM2S 通道: CR=0x00, SR=0x04, DA=0x18, LEN=0x28 S2MM 通道: CR=0x30, SR=0x34, DA=0x48, LEN=0x58 你只使能了 S2MM，所以应该用 0x30 偏移，不是 0x00。

验证

修改偏移后 DMA 正常传输，问题解决。此经验沉淀为 Skill 1。

---

2. INMP441 数据全 0 排查

问题

DMA 能收到数据，但全部是 0，左声道和右声道 RMS 都接近 0。

提示词

```
INMP441 I2S 麦克风数据全 0，可能是什么原因？
我已经确认 BCLK/WS/SD 引脚约束正确，DMA 也能收到数据但全是 0。
L/R 引脚我没接，悬空了。
```

模型回答（关键纠错）

> INMP441 的 L/R 引脚必须接 GND 或 VDD，不能悬空！ - L/R = GND → 左声道输出数据 - L/R = VDD → 右声道输出数据 - 悬空 → 内部状态不确定，可能输出全 0 请用万用表蜂鸣档确认 L/R 到 GND 的导通性。

验证

用户用万用表确认 L/R 未接地，接地后左声道 RMS=753545，数据正常。此经验沉淀为 Skill 1。

---

3. 24bit 音频数据解码错误

问题

录音 WAV 文件离线推理分数高（0.9+），但实时推理分数极低（最高 0.075）。

提示词

```
同样的音频数据，inmp441_record.py 录的 WAV 用模型推理 score=0.9，
但 inmp441_predict.py 实时推理 score=0.075。
record.py 用 raw.astype(np.float64) / 2**23，
predict.py 用 & 0xffffff 掩码 + 手动符号扩展 + 转 int16。
哪个是对的？
```

模型回答（关键纠错）

> 你的 I2S 核是 24bit 右对齐并符号扩展到 32bit。 这意味着硬件已经把 24bit 有符号数符号扩展成了 32bit， 直接 raw / 2**23 就是正确的 float 转换。 用 & 0xffffff 掩码会把符号位抹掉，导致负数变成正数， 信号严重失真，所以推理分数低。 统一用 raw / 223，不要掩码。

验证

修改后实时推理 score 达到 0.9+，与离线一致。

---

4. signal only works in main thread 错误

问题

inmp441_predict.py 用子线程做 DMA 采集，报 `ValueError: signal only works in main thread`。

提示词

```
Python 子线程里调用 signal.alarm 报错 signal only works in main thread，
怎么解决？我的 recv_packet 函数用 signal 做 DMA 超时。
```

模型回答

> signal 模块只能在主线程使用。两种解决方案： 1. 把 DMA 采集放主线程，推理放子线程（推荐，采集是硬实时） 2. 不用 signal，用 MMIO 轮询 SR 寄存器做超时（while 循环 + time.time()）

选择

采用方案1，采集放主线程同步执行，推理用异步线程。修改后稳定运行。

---

5. 录像逻辑设计：固定时长 → 目标存在性

问题

固定时长录像（10秒）录到大量无鸟画面，存储效率低，且鸟还在时录像就结束了。

提示词

```
我需要实现：检测到鸟时开始录像，鸟消失后延迟3秒结束录像，
鸟一直在就一直录。当前是固定10秒录像。怎么改状态机？
```

模型回答（设计方案）

> 用"连续无鸟次数 + 时间跨度"双条件确认目标离开： 1. 检测到鸟 → 启动录像，last_bird_seen=now 2. 录像中持续异步推理 → 有鸟刷新 last_bird_seen，misses=0 3. 无鸟 → misses+=1，记录首次无鸟时间 4. 结束条件：misses >= absence_hits AND span >= absence_sec 5. 故障保护：vision_timeout 无新鲜结果 → 强制结束 推理错误/过期结果必须清零 misses，不能当作鸟离开。

迭代

- 第一版：固定3秒延迟 → 推理慢（6s）导致3秒内推理结果还没回来，无法确认
- 第二版：absence-hits=1 → 一次漏检就结束，太敏感
- 第三版：absence-hits=3, absence-sec=6 → 稳定，后滚约12秒 此经验沉淀为 Skill 4。

---

6. 智能体工作流设计：音频触发图像联动

工作流

```
[音频端] INMP441 → DMA → numpy CNN → 鸟鸣检测
    ↓ 检测到鸟鸣
写 pitta.trigger 文件
    ↓
[图像端] 轮询检测 pitta.trigger → 删除文件
    ↓
WAITING → SEARCHING → YOLOv8n 识别
    ↓ 检测到鸟
保存照片 → 启动录像 → RECORDING
    ↓ 鸟消失
延迟结束 → 回到 WAITING
```

关键设计决策

- **触发文件 vs 网络通信**：选择文件触发，因为两端在同一板子上，文件系统延迟 <100ms，且实现简单
- **音频暂停机制**：录像期间暂停音频推理，避免 CPU 争抢导致图像推理更慢
- **状态机解耦**：音频端和图像端独立进程，通过文件系统通信，崩溃不互相影响

---

7. GEMM 加速器上板踩坑（conv1 硬件化）

把 conv1 从 PS numpy 搬到 PL HLS GEMM 核（`gemm_top`，三路 DMA：A/B 进、C 出） 的过程中，连续遇到 6 个上板问题，全部通过与大模型协作定位。

7.1 S2MM 永不置 IOC（TLAST 缺失）

问题：DMA `recvchannel.transfer(bufC)` 返回后，DMASR 的 IOC 位始终不亮； 缓冲里其实已经有数据，但通道停在 Running，下次 transfer 报错。

提示词：

```
AXI DMA S2MM 通道 transfer 之后 IOC 位一直不置位，但 buffer 里有数据了。
HLS 核输出是 AXI-Stream，可能是什么原因？
```

模型回答（关键纠错）：

> HLS 生成的 stream 在最后一个 beat 没有拉 TLAST。AXI DMA 的 S2MM 靠 TLAST 判断 "一帧结束"，没有 TLAST 它会一直等。两个修法： 1. HLS 设计里给末拍显式拉 TLAST（新版 Vitis HLS 修正了）； 2. 旧 bit 兼容：不要把 S2MM IOC 当完成判据，改用 HLS 核 ap_ctrl 的 ap_done(bit1) 作为计算完成权威判据；S2MM 缺 IOC 时 stop()→sleep 2ms→start() 复位通道复用。

验证：采用兼容方案，`gemm_board.py` 里 `wait_ap_done()` 轮询 ap_done， `_ensure_s2mm_idle()` 在缺 IOC 时复位通道。此经验沉淀为 Skill D1。

7.2 DMA 单次 16 KB 上限

问题：M=12864×N=16×2byte=411 KB 的 C 缓冲，DMA transfer 失败。

提示词：

```
PYNQ AXI DMA recvchannel._size 报 16384 字节，但我需要传 411 KB。
怎么提高单次传输上限？
```

模型回答：

> 这是 AXI DMA IP 的 `c_sg_length_width` 参数，默认 14（2^14=16 KB）。 在 Vivado 里把它改成 23（2^23=8 MB），重新综合即可。板端可以读 `dma.recvchannel._size` 验证是否变成 8388608。

验证：重新综合后 `_size=8388608`，板端脚本加了 FATAL 检查 （`if cap < need:` 报错并提示重新覆盖 `bit/hwh`）。沉淀为 Skill D2。

7.3 PYNQ 默认走中断，中断没接好导致永久挂死

问题：`transfer()` 之后 `wait()` 永远不返回，CPU 单核 100%。

模型回答：

> PYNQ 的 DMA sendchannel/recvchannel 默认等中断回调。如果块图里 DMA 的 irq 没接到 PS 的 pl_ps_irq0，回调永远不来。两个做法： 1. 正确：块图里把 irq 接到 PS，重新综合； 2. 快速：`os.environ["PYNQ_DISABLE_DMA_INTERRUPT"]="1"`，并清空每个 IP 的 `interrupts` 描述，自己用寄存器轮询 DMASR。

验证：采用快速方案，`gemm_board.py` 第 27、143–145 行。沉淀为 Skill D3。

7.4 bit/hwh 版本不一致

问题："我明明改了 TLAST 怎么还是不置 IOC"——因为板上根本是旧 bit。

模型建议：板端启动时硬编码期望 MD5 做自检，不一致就 FATAL 退出； 覆盖文件后必须断电重启或重开 Python 进程（PYNQ Overlay 缓存）。

验证：`verify_board.sh` 与 `gemm_board.py` 的 MD5 自检（`gemm_soc.bit` 期望 MD5 `81714b8306646bbe102e41236a0a3054`）。沉淀为 Skill D5。

7.5 端到端结果

板端 `e2e_board.py --repeat 5` 实测： - numpy 全浮点分数 0.997876； - 硬件 conv1 分数 0.997878； - conv1 205824 点最大误差 0.001838（容差 0.02，0 点超差）； - HLS 核 ap_done 纯计算 6.7 ms；numpy 整网 0.493–0.497 s； - 判定 PASS。

注意：6.7 ms 只是 HLS 核纯计算时间，不含 im2col/Q12/DMA/cache/反量化； 与 numpy 整网 0.497 s 不能直接相除声称加速比。公平加速比待补测。 此口径意识本身也是与大模型协作中反复核对后确立的。

---

8. 提示词模板沉淀

从以上协作过程中提炼的可复用提示词模板，详见 `skill/README.md` Skill 2。

---

9. 模型选择与放弃的候选

候选方案	选择/放弃	原因
ncnn 音频模型	放弃	sound_ncnn.bin 仅 476 字节（onnx2ncnn 未读外部权重），转换失败
numpy 音频模型	选择	用户提供，纯 numpy 实现，无需额外库，精度验证通过
ALSA 音频采集	放弃	/proc/asound/cards 显示 no soundcards，板子无音频编解码器
FPGA DMA 音频采集	选择	I2S 核 + AXI DMA，高吞吐低延迟，不占 CPU
固定时长录像	放弃	存储效率低，鸟还在就结束
目标存在性录像	选择	只录目标相关片段，存储效率高 5-10x
conv1 走 PS numpy（整网）	放弃（已替换）	A9 上整网 0.5 s，conv1 是计算主项之一
conv1 走 PL HLS GEMM	**选择**	im2col 后是规则 GEMM（M=12864 K=9 N=16），Q12 定点；板端 ap_done 6.7 ms，端到端分数与 numpy 一致（max_err 0.001838，0/205824 超差）
FFT+mel 搬 PL	放弃（暂不实施）	分析估算 20×，但 AXI-Stream 乒乓缓冲 + 定点验证工程量大，性价比不高，留作后续

---

10. GEMM 工程缺失：依据 .hwh 反推一键重建

问题

提交前发现 GEMM 加速器只保留了板端 `gemm_soc.bit/.hwh`、HLS IP 源码，**Vivado `.xpr` 工程已不存在**，无法直接导出 GEMM overlay 自身的综合/实现/功耗报告。

与大模型协作的重建过程

1. 解析 `gemm_soc.hwh`，逐一反推出块图：实例（ps7、gemm_top_0、dma_A/B/C、xlconcat、proc_sys_reset）、地址段、AXI 位宽、中断连接；
2. 编写 `build/build_gemm.tcl` 自动重建块图并跑综合/实现/比特流；
3. 三次迭代修复：
4. 手动 `set_property offset` 报只读——automation 已自动分配，删除多余赋值；
5. 时钟/复位引脚名核对（HLS 核为 `ap_clk`/`ap_rst_n`、有 `interrupt`）；
6. **中文工程路径导致 processing_system7 生成失败**——改为在系统英文临时目录建工程，仅把报告写回；
7. 把 HLS IP 从扁平文件重组为完整标准打包目录（`component.xml` + hdl/drivers/xgui/constraints）。

结果

脚本端到端跑通，`build/gemm/` 下生成三份报告（utilization/timing/power）与 bit/hwh： LUT 10.11%、FF 7.05%、BRAM 7.86%、DSP 30.45%、WNS +1.520 ns、功耗 1.741 W。

同步建立的测量工具

- `label_audio_events.py` + `eval_recall.py`：半自动标注 + 事件级召回（在 PC 上完成）；
- `stability_monitor.sh`： 板端连续运行时长监控。

> 关键原则（与大模型反复核对确立）： 真值不能用模型自身输出代替；公平加速比必须同板同口径； 估计值必须标注。这些都写进了 `skill/SKILL.md` 的判定口径。